基于 Wikidata 电影知识图谱的问答系统与答案生成实验报告

人工智能 I 课程实验

本报告记录电影单跳知识图谱问答实验的实际数据构建、模型实现、参数调整、统一评测和结果分析。实验比较可解释的管道式方法与融合 TransE 结构向量的 FLAN-T5 生成方法，并通过学习率对照和嵌入消融判断主要性能变化。

二 实验基本信息

项目	内容
实验名称	基于知识图谱的问答系统与答案生成
姓名	待填写
学号	待填写
班级	待填写
实验完成日期	2026 年 9 月 12 日

三 实验环境

项目	实际配置
操作系统	Windows-10-10.0.26200-SP0
Python 路径	H:\AI1experiment\.venv\Scripts\python.exe
Python 版本	3.11.7
CPU	12th Gen Intel(R) Core(TM) i7-12700H，20 个逻辑处理器
内存	15.8 GB
GPU	NVIDIA GeForce RTX 3070 Ti Laptop GPU, 8192 MiB, 610.88
CUDA	可用，PyTorch CUDA 12.4
主要依赖	torch 2.6.0+cu124, transformers 4.48.3, pykeen 1.11.1, scikit-learn 1.6.1, sacrebleu 2.5.1, rouge-score 0.1.2, numpy 1.26.4, pandas 2.2.3

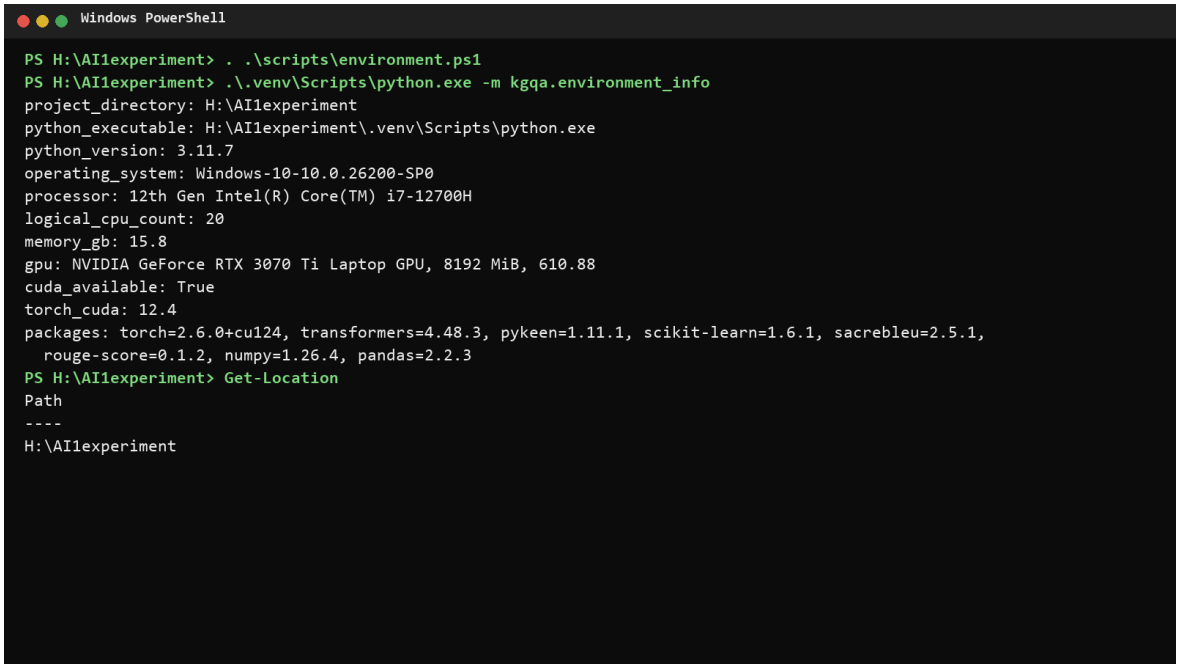


图 1 终端环境配置记录

四 数据集与实验设置

数据来自 Wikidata 的电影子图，使用导演 P57、类型 P136、制作国家 P495 和原始语言 P364 四类关系。冻结快照的 SHA-256 为 eb85268c3359238b7eeed2438e3693c5e42ab2de09ce4a32d4137a5196613739，包含 1000 部电影、2285 个实体、6194 条三元组和 12267 条问答。

数据项	数量或设置
训练集问答	8587
验证集问答	1825
测试集问答	1855
电影实体划分	700 / 150 / 150
随机种子	42
划分原则	按电影 QID 分组，同一电影的原问题和改写位于同一集合

A0 采用电影标题与别名词典完成实体链接，使用词和字符 TF-IDF 特征及逻辑回归判断关系，再查询冻结子图并通过模板生成完整句。B0 至 B3 采用 FLAN-T5-small，以问题和相关三元组文本为输入，并将冻结的 TransE 头实体、关系和尾实体向量投影为结构前缀。C0 保留相同三元组文本，但移除结构向量。

五 实验结果

5.1 基础实验设置与运行记录

正式实验固定使用上述数据划分。A0 的关系置信度阈值在验证集上选择；所有神经模型均从同一 FLAN-T5-small 初始权重独立训练，使用随机种子 42，测试集只在验证选模完成后评估一次。

模块	主要参数
A0	TF-IDF + 逻辑回归；验证选择阈值 0.30
TransE	维度 100；学习率 0.001；batch size 256；100 epoch；每个正例 5 个负样本
B0	学习率 1e-04；5 epoch；batch size 16；有效 batch size 16；BF16 自动混合精度
选模指标	验证集答案实体 Macro-F1

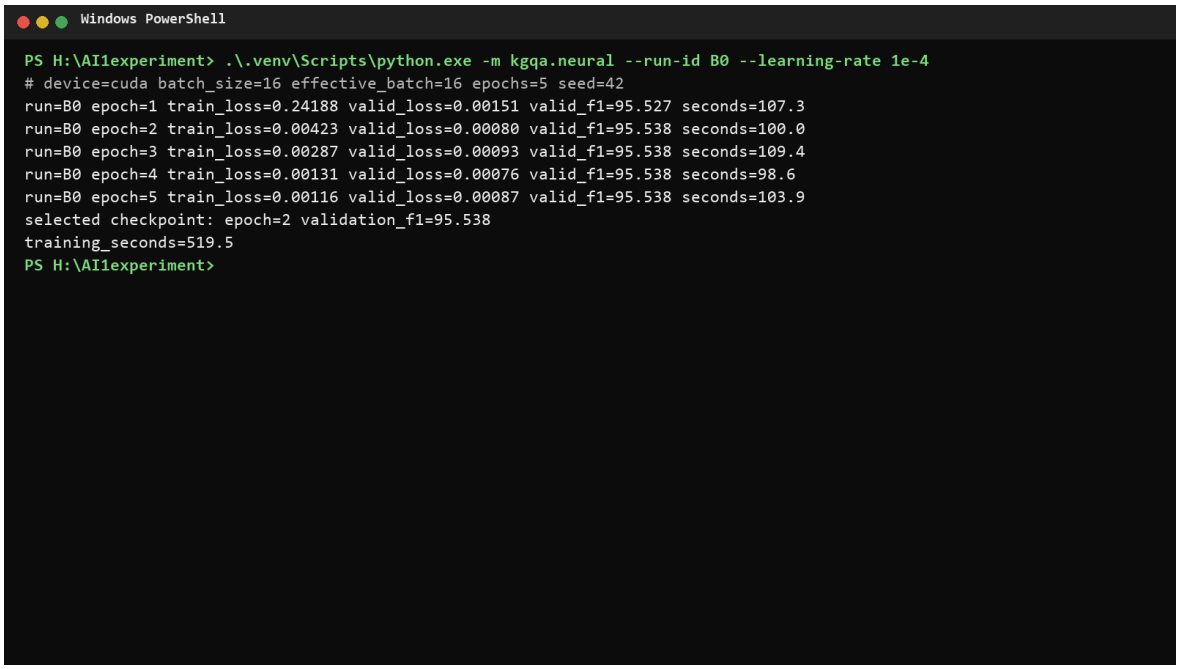


图 2 B0 模型训练过程记录

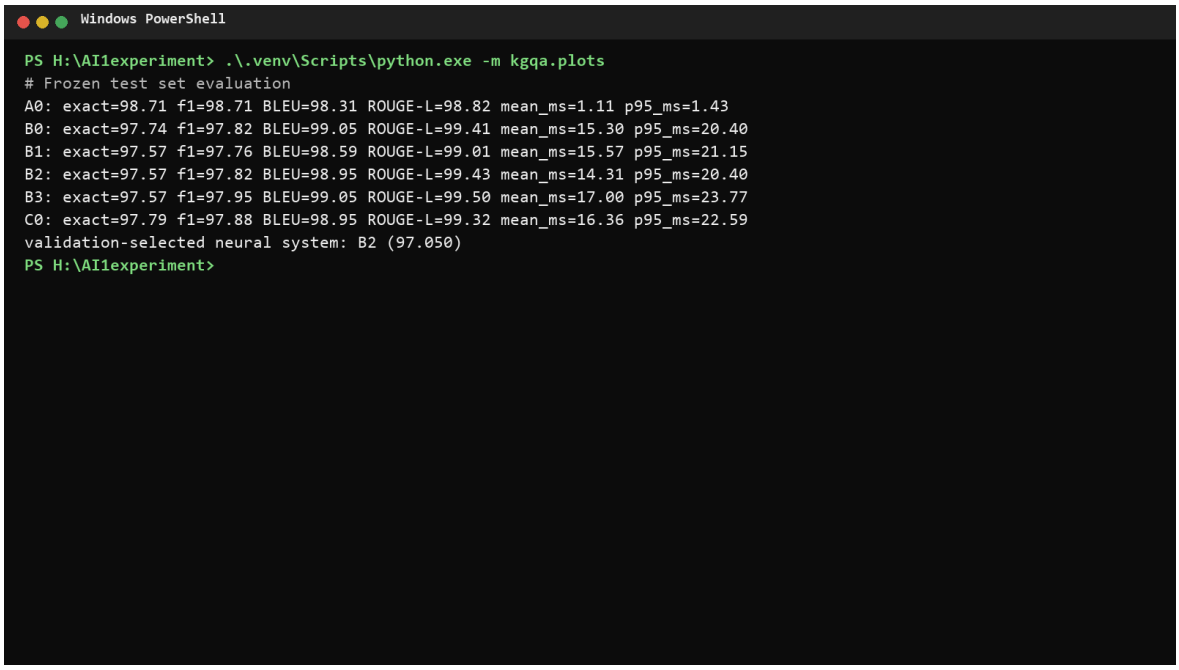


图 3 测试评估与参数实验运行记录

5.2 基础实验结果

实验	实体准确率	实体 F1	BLEU	ROUGE-L	平均延迟 ms	P95 延迟 ms	训练 min
A0	98.71	98.71	98.31	98.82	1.11	1.43	-
B0	97.74	97.82	99.05	99.41	15.30	20.40	8.7

A0 的实体集合准确率为 98.71%，Macro-F1 为 98.71%，平均延迟为 1.11 ms。B0 的实体集合准确率为 97.74%，Macro-F1 为 97.82%，BLEU 为 99.05，ROUGE-L 为 99.41。B0 文本重叠指标较高，但多答案问题存在漏答，使集合完全匹配指标低于实体 F1。

5.3 参数修改与重复实验

实验	学习率	TransE	最佳 epoch	验证 F1	训练 min
B0	1e-04	使用	2	96.88	8.7
B1	3e-05	使用	3	96.73	8.0
B2	3e-04	使用	2	97.05	8.5
B3	1e-03	使用	4	96.92	8.5
C0	1e-04	移除	2	95.54	8.3

B0 至 B3 仅改变学习率，数据、训练轮数、随机种子、模型初始权重和其他超参数保持一致。C0 与 B0 使用相同学习率和三元组文本，仅移除 TransE 结构前缀。

5.4 基础实验与参数修改实验的结果对比

实验	实体准确率	实体 F1	BLEU	ROUGE-L	平均延迟 ms	P95 延迟 ms	训练 min
B0	97.74	97.82	99.05	99.41	15.30	20.40	8.7
B1	97.57	97.76	98.59	99.01	15.57	21.15	8.0
B2	97.57	97.82	98.95	99.43	14.31	20.40	8.5
B3	97.57	97.95	99.05	99.50	17.00	23.77	8.5
C0	97.79	97.88	98.95	99.32	16.36	22.59	8.3

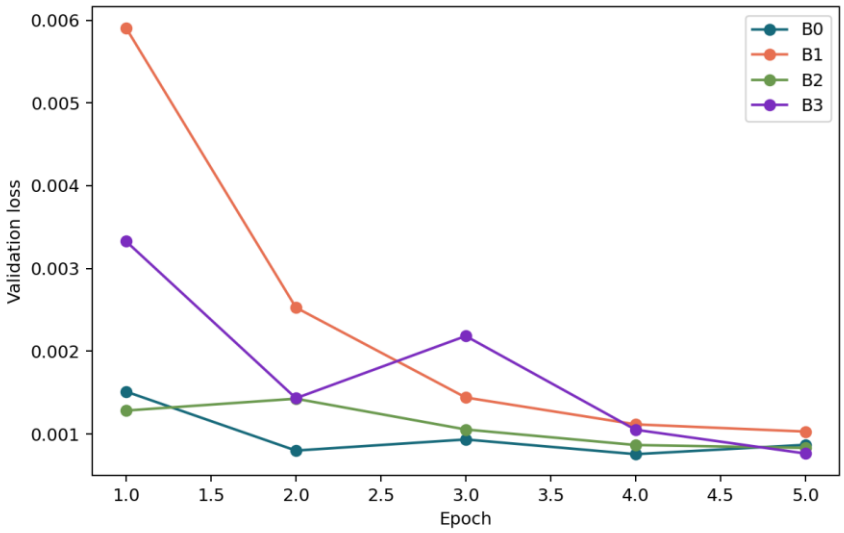


图 4 不同学习率下的验证损失曲线

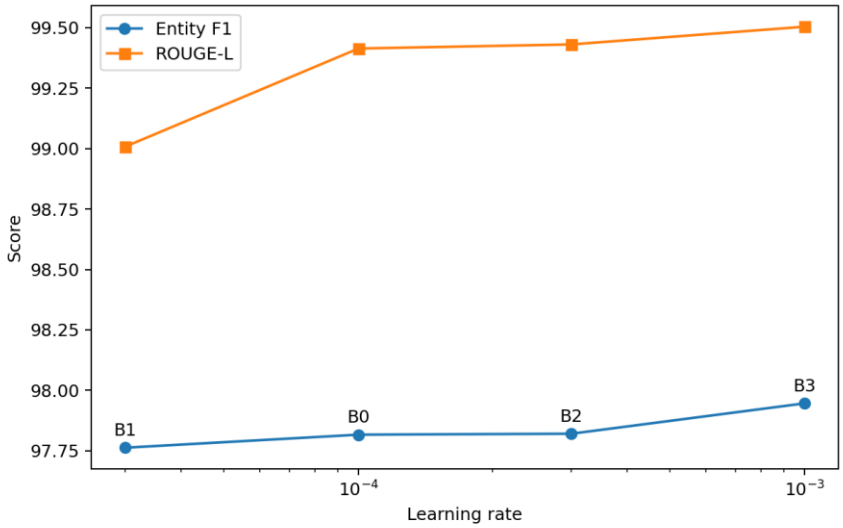


图 5 学习率与最终测试指标

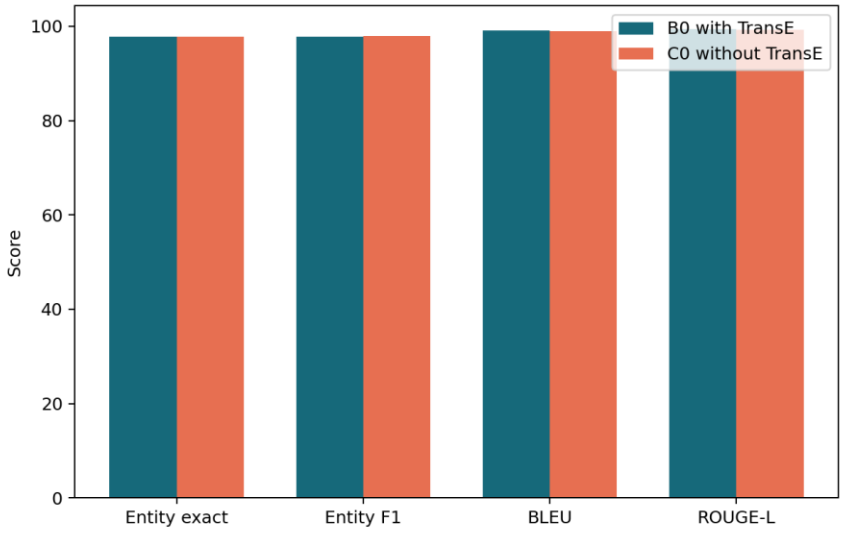


图 6 TransE 结构向量消融对比

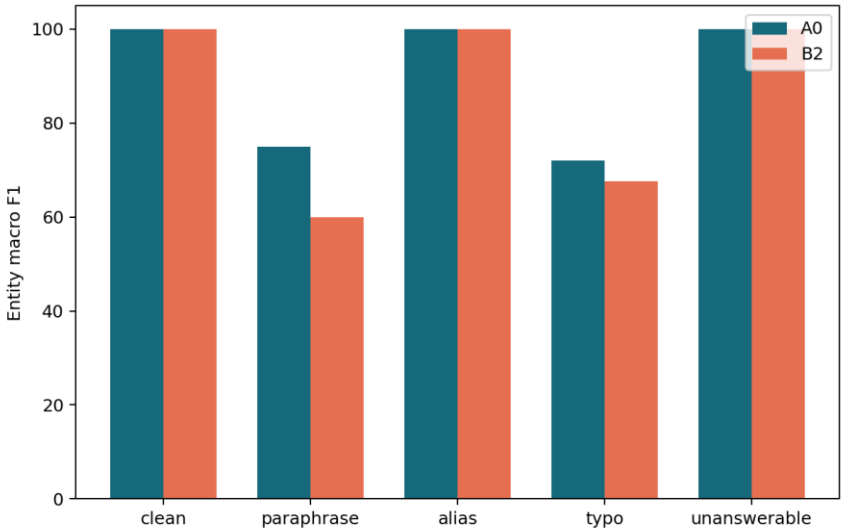


图 7 A0 与最佳神经系统的鲁棒性对比

5.5 结果对比分析

参数修改后，四组学习率的测试实体 Macro-F1 分布在 97.76% 至 97.95% 之间。按验证集 F1 选择的模型为 B2，其验证 F1 为 97.05%；若只观察测试集，最高的是 B3（97.95%），最低的是 B1（97.76%）。模型选择严格依据验证集，未使用测试集反向挑选参数。

嵌入消融中，B0 的实体 Macro-F1 为 97.82%，C0 为 97.88%。加入 TransE 后该指标降低 0.06 个百分点。由于两组仍保留相同三元组文本，这一差值反映结构向量在本次单种子实验中的附加影响。

鲁棒性结果为：clean：A0 100.00%，B2 100.00%；paraphrase：A0 75.00%，B2 60.00%；alias：A0 100.00%，B2 100.00%；typo：A0 72.00%，B2 67.67%；unanswerable：A0 100.00%，B2 100.00%。实体链接错误、关系改写覆盖不足和拼写噪声是主要下降来源；生成系统还可能出现多答案漏答。学习率过低会限制五轮内的参数更新，过高则可能使收敛波动增大，因此最终结果需要结合验证损失曲线和实体 F1 共同判断。

逐题错误归因结果为：A0：实体链接错误 27 题；B2：无依据答案实体 3 题，实体链接错误 27 题，漏答 18 题。该归因按实体链接、关系识别、漏答、答案不完整、无依据实体和拒答失败的顺序判定。

本次结果总体符合预期：A0 在固定单跳事实查询上具有较高精确性和极低延迟，神经模型的语言生成质量较好，但严格集合匹配会受到漏答影响。结论只适用于本次固定知识库、单次随机种子和电影单跳任务，不推断模型能够回答知识库之外的未知事实。

人工评价表已生成，准确性、完整性、流畅度和无依据生成字段必须由实验者逐题核查后填写；本报告不以自动指标代替人工事实评价。

六 实验总结

本实验完成了 Wikidata 数据冻结、按电影实体划分、A0 管道问答、TransE 嵌入、五组 FLAN-T5 训练、统一评测、鲁棒性测试和嵌入消融。实际结果表明，B2 在验证集上得到最高实体 F1；A0 在固定事实查询上更容易保持集合精确匹配和低延迟。实验也说明，文本相似度高并不保证多答案实体集合完全正确，知识图谱问答应同时报告实体级指标、文本指标、拒答能力、鲁棒性和运行成本。

参考资料包括 Wikidata 数据访问文档、TransE 原始论文、PyKEEN 文档、FLAN-T5 模型卡、WebNLG、SacreBLEU 和 ROUGE 论文。完整数据查询和实验设计见项目文件《实验设计与参考资料》。

七 参考资料

[1] Wikidata. Wikidata Query Service User Manual. https://www.wikidata.org/wiki/Wikidata:SPARQL_query_service/Wikidata_Query_Help

[2] Wikidata. Data access and entity data documentation. https://www.wikidata.org/wiki/Wikidata:Data_access

[3] Bordes A, Usunier N, Garcia-Duran A, et al. Translating Embeddings for Modeling Multi-relational Data. NeurIPS, 2013.

[4] Ali M, Berrendorf M, Hoyt C T, et al. PyKEEN 1.0: A Python Library for Training and Evaluating Knowledge Graph Embeddings. JMLR, 2021.

[5] Google. FLAN-T5-small model card. https://huggingface.co/google/flan-t5-small

[6] Gardent C, Shimorina A, Narayan S, Perez-Beltrachini L. Creating Training Corpora for NLG Micro-Planners. ACL, 2017.

[7] Post M. A Call for Clarity in Reporting BLEU Scores. WMT, 2018.

[8] Lin C Y. ROUGE: A Package for Automatic Evaluation of Summaries. ACL Workshop, 2004.